UNIVERSITÉ
CAEN
NORMANDIE

Rapport de projet tuteuré : Reconnaissance automatique d'image de plat

Sujet proposé par Marc Houssaye, directeur de MH-COMMUNICATION
Encadré par François Rioult, enseignant-chercheur UCBN (GREYC)
Université de Caen Normandie - M2-DNR2i
Code visualisable sur github

Pierre Labadille

22 février 2017

Table des matières

Chapitre 1

Introduction

Le domaine du web est un secteur d'innovation et d'évolution très rapide. La quantité de données, d'applications et d'informations y croit de façon exponentielle depuis plusieurs années.

« *Chaque seconde, 29.000 Gigaoctets (Go) d'informations sont publiés dans le monde, soit 2,5 exaoctets par jour soit 912,5 exaoctets par an. Un volume de "big data" qui croît à une vitesse vertigineuse et donne naissance à de nouveaux types de statistiques.* **- planetoscope.com** »

Comme l'indique ces statistiques, cette masse de données ainsi que les évolutions des systèmes de crawling [1] induisent de nouvelles problématiques : il n'est aujourd'hui plus possible, sans des ressources considérables, de vérifier et assembler des données à la main sur des systèmes basés sur du crawl automatique.

1.1 Présentation du projet

RestoFolio est une application web innovante proposant de trouver un restaurant par le biais d'un plat précis ou plutôt grâce à une photo de celui-ci.

Actuellement, Restofolio récupère des données (images et informations) de milliers de restaurants à l'échelle de la France entière toutes les nuits. Précédemment, l'application n'opérait qu'à une échelle locale (quelques villes de la région) et la validation de ces images était manuelle. Cette validation qui n'était déjà pas optimale à petite échelle est donc aujourd'hui impossible.

La solution à court terme qui a été choisie est l'utilisation de l'API Vision de Google [2] qui offre un système de classification automatique d'image performant. Cependant elle a également des limites : l'utilisation de cette dernière n'est pas gratuite, elle n'est pas contrôlée par l'entreprise (mais par un service extérieur) et elle n'est pas spécialisée.

1.2 Objectifs et problème de départ

Le problème de départ est plutôt simple et peut être formulé de cette façon : ***"cette photo est-elle un plat ?"***. De cette simple question découlent néanmoins des problèmatiques bien plus complexes :

1. Crawl : récupération automatique de contenu
2. Plus d'information sur cette API plus tard dans le rapport

— Comment une machine peut-elle reconnaitre automatiquement une photo ?
— Qu'est-ce qu'un plat ?
— Comment distinguer un plat d'une photo de légume, ou d'une photo de plusieurs plats ?
— Comment connaître la fiabilité de la réponse ?

N'ayant absolument aucune connaissance dans ce domaine d'expertise, l'objectif principal de ce projet sera d'identifier la meilleure solution possible à la problématique exposée ci-dessus et de la mettre en application.

En fonction de la complexité de la solution choisie, l'objectif secondaire serait d'améliorer cette solution en ajoutant un système d'étiquetage de plat en fonction de leur nature.

J'ai organisé ce rapport de façon chronologique afin de présenter le raisonnement qui a conduit à la solution finale proposée dans ce projet. Dans un premier temps, je présenterai comment j'ai choisi l'environnement et les technologies utilisés. Dans un second temps, je détaillerai l'aspect technique lié au développement. Enfin, j'exposerai les résultats et performances du modèle.

Chapitre 2

Recherches et choix des technologies

2.1 Analyse des outils préexistants

Tous les outils (fonctionnels) préexistants que j'ai pu trouver en la matière sont des API. Je me suis donc renseigné et j'ai testé ces API qui ont souvent beaucoup de points communs et qui exploitent pour la majorité des réseaux de neurones de classification d'image.

2.1.1 Les géants

Voici une liste non exhaustive des API les plus réputées dans le domaine de la reconnaissance automatique d'image :

— API Vision Google
— Clarifai API
— API Cloudsight
— Microsoft Computer Vision
— IBM Visual Recognition

Ces API fonctionnent sur des modèles différents mais proposent toutes globalement la même chose : une classification automatique d'image par le biais de prédictions classées par seuil de confiance.

Toutes sont clairement performantes et retournent sur leurs premières prédictions un seuil de confiance supérieur à 90% dans la majorité des cas. Elles sont néanmoins trop généralistes et les "labels" retournés varient énormément. Un exemple concret serait le suivant :

En soumettant une photo d'escalope à la crème dans une assiette, on aura comme premier résultat "meat : 95.2562%". En soumettant maintenant une pièce de viande brute, on aura "meat : 96.589%".

Ces API proposent une multitude de labels et chacun peuvent être assignés de façons différentes (un même plat n'aura que rarement le même label si la photo n'est pas la même car le système constatera une certaine différence qui fera pencher la balance un peu plus vers un autre label). N'étant également pas spécialisées, elles ne font pas la différence entre un snack et un plat par exemple.

En termes de résultats, les scores sont très serrés sur ces API : certaines sont meilleures que d'autres dans un domaine, mais cela reste difficile à juger car elles sont toutes très fiable (selon plusieurs sources, Clarifai serait la plus performante juste devant Google). Enfin, l'API Cloudsight est sujette à de nombreux doutes sur sa solution "automatisée". Il est possible qu'elle ne passe pas par des réseaux de neurones mais plutôt par des "fermes à clic" pour retourner des prédictions [1].

2.1.2 Les autres

Ces API sont moins réputées mais généralement spécialisées dans la reconnaissance d'images représentant de la nourriture ce qui leurs donne un avantage par rapport aux plus connues. Cette liste n'est pas exhaustive :

— FOODAi Smart Food Recognition
— Imagga's Image Recognition
— Intelligent image recognition
— 8bit API

L'avantage principal de ces solutions par rapport aux précédentes est qu'elles sont plus claires en termes de tagging car spécialisées dans le domaine culinaire.

Elles ont cependant une fiabilité inférieure aux modules réputés et leurs pérennités n'est pas toujours assurée ce qui est désavantage majeur.

Enfin, elles échouent également sur la différenciation d'un plat et de nourriture non cuisinée ou non dressée [2].

2.2 Les réseaux de neurones

Nous avons exposé dans la section précédente que les API disponibles sur le marché n'étaient pas forcément la meilleure solution à notre problème. Elles sont trop généralistes et leurs modèles ne sont pas conçus pour répondre directement à notre problématique de reconnaissance de plat.

Néanmoins elles semblent toutes exploiter des modèles de réseau de neurones [3] et il semble donc pertinent de s'attarder sur cette technologie. En effet, leur modèle ne correspond pas à notre besoin mais la solution peut se trouver dans un modèle adapté.

« *Un réseau de neurones artificiels, ou réseau neuronal artificiel, est un ensemble d'algorithmes dont la conception est à l'origine très schématiquement inspirée du fonctionnement des neurones biologiques, et qui, par la suite, s'est rapproché des méthodes statistiques.* **- Wikipedia** »

Notre problème initial ne se pose pas car les humains ne sont physiquement pas apte à faire cette validation mais bien car cette tâche est ingrate et qu'elle est devenue impossible pour des raisons financières évidentes. Cette définition semble donc confirmer la pertinence des réseaux de neurones : s'ils sont basés sur la même logique de réflexion que nous et que

1. Cf Comparing the Top Five Computer Vision APIs
2. Le dressage d'un plat correspond à l'étape précédent le service du plat : c'est la mise en valeur de celui-ci.
3. Deep Learning: présentation simple et détaillée parue dans Le Monde

nous étions capables de faire ce travail à la base, il n'y a pas de raison qu'on ne puisse pas valider nos images efficacement par ce biais.

Qu'en est-il de la fiabilité de cette technologie qui est encore très jeune et qui est de plus en plus présente depuis ces 2 dernières années ? Et bien les évolutions en la matière ont été démesurée... là où il y a quelques années, les meilleurs modèles peinaient à atteindre les 60-70% de précision, ils atteignent aujourd'hui les 97% de précision [4].

2.3 Choix du modèle et de l'environnement

J'ai choisi d'utiliser la librairie logicielle Tensorflow pour développer mon modèle qui est actuellement la plus performante et polyvalente en matière de deep learning. [5]

« *TensorFlow™ is an open source software library for numerical computation using data flow graphs. Nodes in the graph represent mathematical operations, while the graph edges represent the multidimensional data arrays (tensors) communicated between them. The flexible architecture allows you to deploy computation to one or more CPUs or GPUs in a desktop, server, or mobile device with a single API.* **- Tensorflow** »

Néanmoins, j'apprécie la logique du développement modulaire et dans ce sens, j'ai choisi de rajouter une couche en développant mon modèle avec Keras qui permet de simplifier la gestion du GPU pour le calcul mais également de développer des modèles facilement compatibles entre Tensorflow et Thenao [6].

« *Keras is a high-level neural networks library, written in Python and capable of running on top of either TensorFlow or Theano. It was developed with a focus on enabling fast experimentation. Being able to go from idea to result with the least possible delay is key to doing good research.* **- Keras** »

Enfin, le modèle qui m'a paru le plus pertinent à développer est un ConvNet [7] binaire (et non multi classe).

La justification pour l'utilisation d'un modèle ConvNet est très simple : c'est la référence de base de tous les modèles de reconnaissance automatique d'image.

Le choix de faire un modèle binaire (seulement deux classes) est lié à deux raisons :

— Une raison technique : les modèles multi classe conventionnels (ceux proposés par les API) ne conviennent pas notamment car il cherche à épingler une classe à une image. Dans notre problème on ne s'intéresse pas forcément à l'assignation de classe, mais on veut simplement savoir si oui ou non une photo est un plat.

— Une raison personnelle : les modèles multi classes sont beaucoup plus complexe à mettre en place or je manque d'expérience et de temps pour m'y atteler.

4. Cf Machine Learning Attacks Against the Asirra CAPTCHA
5. Cf Explication informelle des différences entre Tensorflow et les autres librairies
6. Théano est le principal concurent de Tensorflow
7. ConvNet : Deep Convenlutional Network

Chapitre 3

Développement et optimisation

3.1 Mise en place de l'environnement

3.1.1 Specificité système et configuration

Après mes recherches sur les réseaux de neurones j'ai vite compris qu'il était nécessaire d'avoir une bonne machine pour faire de l'apprentissage. J'ai donc dû exclure mon pc portable qui n'a pas de carte graphique.

En effet, pour ce genre de calcul le GPU est bien plus efficace que le processeur. J'ai donc dans un premier temps décidé d'installer une version Ubuntu sur mon PC Fixe mais sans succès (mon processeur est trop récent et obtenir un simple affichage graphique a déjà été un challenge).

Après quelques recherches j'ai été très étonné de voir que Tensorflow venait officiellement d'ajouter un support pour Windows et que cette version était parfaitement stable. C'est donc pour cette raison que toute la partie apprentissage de ce projet a été réalisée sur Windows10.

Une des contraintes majeures pour le développement de réseau de neurones est le hardware. En effet, j'ai été très surpris de voir que la plupart des modèles sont entrainés avec des configurations très pointues (généralement plusieurs TITAN X PASCAL, des processeurs de calculs professionnels et quelques centaines de Go de mémoire vive). N'ayant évidement ni les moyens, ni le temps d'acquérir du matériel de calculs de pointe, je me suis tourné vers mon PC Fixe qui à une configuration gamer suffisante pour cette tâche :

— Processeur Intel Core i7 4790k (4,28GHz, 4 coeurs physiques)
— 2 Nvidia GeForce GTX970 (4Go GDDR5 par carte)
— 16Go DDR3 GSkill

Enfin l'installation des "Cuda dev tools" ainsi que de cuDNN [1] a été nécessaire pour permettre à mes cartes graphiques de faire le calcul à la place du CPU.

3.1.2 Environnement

Tensorflow propose deux langages de développement : le C++ ou Python. Je me suis naturellement orienté vers Python (3.5) que je maitrisais déjà et pour lequel plus d'exemples sont disponibles.

1. cuDNN 5.1 : NVIDIA CUDA® Deep Neural Network library (cuDNN) is a GPU-accelerated library of primitives for deep neural networks

La seconde contrainte majeure pour le développement de réseau de neurones est la gestion des dépendances : chaque version doit être compatible avec le système ainsi qu'avec Tensorflow. De plus, Keras s'accompagne également de son lot de dépendance rendant la tâche d'autant plus complexe. C'est la raison pour laquelle j'ai décidé d'utiliser la librairie Python Anaconda [2].

Enfin, pour pouvoir générer des graphes et des exemples à la suite des phases d'apprentissage, j'ai choisi d'utiliser le notebook Jupyter [3]

Les principales librairies utilisées dans ce projet sont les suivantes :
— Scipy : écosystème Python de logiciel open-source pour mathématiques, sciences et ingénierie.
— Scikit-learn : Outil simple et efficace pour le data mining et l'analyse de données.
— Seaborn : Librairie Python de visualisation basée sur Matplotlib (Scipy). Elle propose une interface de haut niveau pour générer des graphiques statistiques.

3.2 Création du jeu de données

3.2.1 Approche

Cette étape est primordiale dans le bon fonctionnement d'un réseau de neurone. Si le jeu de donnée de chacune des classes n'est pas cohérent le modèle ne sera pas pertinent.

J'ai dans donc dans un premier temps réfléchie aux données qu'il serait pertinent d'ajouter à chacune des deux classes. L'une de ces deux classes contient donc des images qui sont des plats, l'autre contient des images d'éléments qui ne sont pas des plats et que l'on ne souhaite pas voir catégoriser comme tel.

J'ai élaboré ces jeux de données en créant des sous-classes avec l'idée de ne pas avoir à retrier ces données encore une fois pour passer le modèle en multi-classe ou pour concevoir un second modèle.

3.2.2 Classe cookedDish

Cette classe à pour objectif d'apprendre à notre modèle ce qu'est notre définition d'un plat. En l'occurence nous ne nous intéressons qu'à des plats cuisinés et correctement présentés. L'absence de présence humaine sur la photo est également souhaitée.

Pour correctement apprendre au modèle à reconnaitre un plat j'ai décidé d'utiliser un data-set déjà existant : ETHZ-Food101 [4] qui est composé de 101 classes de plats cuisinés (de 1000 images chacune) correspondants au plus populaires sur le site foodspotting.com.

2. Anaconda : high performance distribution of Python and R and includes over 100 of the most popular Python, R and Scala packages for data science

3. Jupyter notebook : The Jupyter Notebook is a web application that allows you to create and share documents that contain live code, equations, visualizations and explanatory text.

4. Food-101 – Mining Discriminative Components with Random Forests. Authors : Bossard, Lukas and Guillaumin, Matthieu and Van Gool, Luc (2014)

(a) Salade Grecque

(b) Pad Thaï

(c) Cheese Cake

FIGURE 3.1 – Exemple de photo du dataset

3.2.3 Classe non-cookedDish

Pour cette classe je n'ai pas pu utiliser un dataset préexistant car aucun dataset ne se focalise sur "je ne suis pas un plat". Ma démarche a donc était totalement différente.

J'ai dans un premier temps classé en différentes catégories 3.000 images (fournie par Restofolio) qui avaient été manuellement rejeté par RestoFolio. De cette façon, j'ai pu voir les types d'images qui ne sont pas des plats les plus souvent ajoutés par les restaurateurs : photo de la salle du restaurant, de la carte/ardoise, publicité ou encore de matière première pour n'en citer que quelques uns.

J'ai ensuite peuplé ces différentes catégories à partir de petits dataset trouvés sur le web afin de rééquilibrer les deux classes. J'ai enfin ajouté deux dataset de contenus divers (et qui ne contiennent pas de photo de plat) afin de prévoir certaines classes oubliées. [5]

(a) Légumes brut

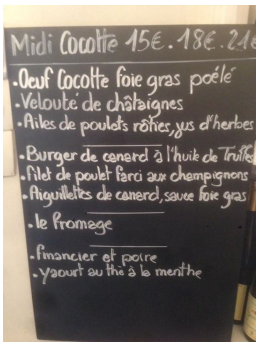

(b) Ardoise

(c) Bouteilles de vin

FIGURE 3.2 – Exemple de photo du dataset

3.2.4 Préparation du set de données utilisé

Comme indiqué précédemment, le dataset de deux classes a été scindé en plusieurs sous-classe pour une utilité future. Pour le réseau actuel de neurones toutes les données doivent être dans le même dossier afin de faciliter leurs lectures.

5. Toutes les classes ainsi que les dataset utilisé peuvent être consultées directement sur un readme disponible sur le github du projet.

J'ai donc établi une normalisation du dataset dans le dossier contenant les images nécessaires à l'entrainement et la validation : <**classe**>_<**i**>**.jpg**. Renommer et déplacer 200.000 images réparties dans de multiples dossiers n'étant pas une option, j'ai opté pour la création d'un simple script bash :

mvIterator.sh

```
#!/bin/bash

total=0
for folder in *; do
    if [ $folder != *".sh" ]
        then
        i=0
        for img in ${folder}/*; do
            ((i++))
            mv ${img} ${folder}_${i}".jpg"
        done
        ((total+=i))
    fi
done
echo "You have moved and rename $total files"
```

3.3 Développement du modèle

Dans cette section je vais présenter les extraits principaux du code du modèle afin d'expliquer le fonctionnement du modèle et de chacune de ses spécificités. Le code original dans son intégralité est visualisable sur le github du projet. Veuillez noter qu'il existe deux versions du modèle et du système de prédiction :

- La première ne peut être executée que dans un notebook Jupyter et permet d'avoir des indicateurs visuels sur les résultats du modèle.
- La seconde peut être executée directement en console (dans un environnement Tensorflow) mais ne donnera que des informations textuelles sur le modèle.

3.3.1 Le modèle (cookedDishModel.py)

Tout d'abord, je souhaite préciser que la base de ce code ne vient pas de moi. J'ai pris modèle sur un Convnet starter de Jeff Delanay, lui-même fortement inspiré du tutoriel Building powerful image classification models using very little data de Francois Chollet.

Les différences principales avec ces deux modèles sont indiquées en commentaire dans le code au début du script. Globalement, j'ai fais du refactoring, adapté le modèle au besoin et ajouté plusieurs améliorations que je vais vous présenter maintenant (une cross validation par exemple).

Dans un premier temps, le script importe les dépendances du modèle puis on va stocker la localisation des images en numpy array [6] afin de pouvoir les apprendre au modèle. Ces images vont ensuite être redimensionnées (le modèle a besoin d'avoir des images de la même taille) et converties afin que le modèle puisse la comprendre.

6. Table d'index sous forme de tableau multidimensionnel (ici 3d)

C'est après que la logique binaire de notre modèle va prendre naissance, le snippet suivant montre comment l'on assigne chaque image à ça classe respective :

cookedDishModel.py (l.96)

```
labels = []
for i in train_images:
  if 'cookedDish' in i:
    labels.append(1)
  else:
labels.append(0)
```

On va ensuite définir notre modèle. Un modèle est composé de différentes couches. Dans le cas présent, notre modèle est une version réduite de l'architecture VGG16 [7]

Dans notre cas vous pouvez voir l'utilisation de quatre blocs convolutionnels [8] ainsi qu'un "fully-connected" classifieur [9]. Grossièrement, chaque couche convenlutionelle n'a accès qu'aux couches inférieures : l'apprentissage du modèle passe par elles (on dit qu'elles sont connectées localement). La couche "fully-connected", elle, a accès à tout le modèle : c'est par elle que sont faites les prédictions après la période d'apprentissage. Enfin l'optimisateur et l'objectif sélectionné sont préconisés pour les modèles de classification binaire.

cookedDishModel.py (l.133)

```
optimizer = RMSprop(lr=1e-4)
objective = 'binary_crossentropy'

def isPlat():
  model = Sequential()

  model.add(Convolution2D(32, 3, 3, border_mode='same', input_shape
      =(3, ROWS, COLS), activation='relu'))
  model.add(Convolution2D(32, 3, 3, border_mode='same', activation='
      relu'))
  model.add(MaxPooling2D(pool_size=(2, 2), dim_ordering="th"))

  model.add(Convolution2D(64, 3, 3, border_mode='same', activation='
      relu'))
  model.add(Convolution2D(64, 3, 3, border_mode='same', activation='
      relu'))
  model.add(MaxPooling2D(pool_size=(2, 2), dim_ordering="th"))

  model.add(Convolution2D(128, 3, 3, border_mode='same', activation='
      relu'))
  model.add(Convolution2D(128, 3, 3, border_mode='same', activation='
      relu'))
  model.add(MaxPooling2D(pool_size=(2, 2), dim_ordering="th"))

  model.add(Convolution2D(256, 3, 3, border_mode='same', activation='
      relu'))
  model.add(Convolution2D(256, 3, 3, border_mode='same', activation='
      relu'))
  model.add(MaxPooling2D(pool_size=(2, 2), dim_ordering="th"))
```

7. architecture VGG16 : réseau à 16 couches utilisés par l'équipe VGG pour la compétition ILSVRC-2014 competition. Cf Very Deep Convolutional Networks for Large-Scale Image Recognition
8. Cf Convolutional Layer
9. Cf Fully-connected layer

```
22
23          model.add(Flatten())
24          model.add(Dense(256, activation='relu'))
25          model.add(Dropout(0.5))
26
27          model.add(Dense(256, activation='relu'))
28          model.add(Dropout(0.5))
29
30          model.add(Dense(1))
31          model.add(Activation('sigmoid'))
32
33          model.compile(loss=objective, optimizer=optimizer, metrics=['
                accuracy', 'recall', 'precision'])
34          return model
35
36      model = isPlat()
```

Le petit bout de code ci-dessous va permettre d'appliquer la méthode de "cross validation" lors de l'apprentissage. Cela signifie qu'à chaque nouvelle epoch, [10] le jeu d'apprentissage et le jeu de validation va être modifié de façon aléatoire (définie par l'attribut "random_state").

cookedDishModel.py (l.175)

```
1       X_train, X_test, y_train, y_test = train_test_split(train, labels,
            train_size=VALIDATION_PERCENT, random_state=RANDOM_STATE)
```

Cette petite classe est indispensable pour avoir des statistiques précises sur l'apprentissage de notre modèle. Grâce à une callback, elle nous permet de récupérer des informations sur les performances de notre modèle à chaque epoch. Les attributs préfixés par "val_" correspondent aux statistiques de validation, les autres à l'apprentissage.

cookedDishModel.py (l.177)

```
1       class trendsHistory(Callback):
2         def on_train_begin(self, logs={}):
3           self.losses = []
4           self.val_losses = []
5           self.acc = []
6           self.val_acc = []
7
8         def on_epoch_end(self, batch, logs={}):
9           self.losses.append(logs.get('loss'))
10          self.val_losses.append(logs.get('val_loss'))
11          self.acc.append(logs.get('acc'))
12          self.val_acc.append(logs.get('val_acc'))
```

L'avantage de permettre à un modèle de parcourir plus d'une epoch est qu'il améliore ça capacité à généraliser et devient plus performant réduisant ainsi ce que la losses [11] du modèle. Cependant après un certain temps le modèle va commencer à trop généraliser et cette accumulation de données va alors inverser cette tendance. La fonction ci-dessous permet d'arrêter le modèle avant le nombre d'epoch prédéfini dans le cas où la losses de

10. Un epoch correspond à un cycle complet d'apprentissage (toutes les données sont passées au moins une fois)
11. somme des carrés résiduels des erreurs du modèle

validation ne diminue plus. Elle est accompagnée d'un délai afin de se prémunir de fausses alertes.

cookedDishModel.py (l.191)

```
## Early stopping if the validation loss doesn't decrease anymore
early_stopping = EarlyStopping(monitor='val_loss', patience=
    EARLY_SOPPING_PATIENCE, verbose=1, mode='min')
```

Enfin, cette fonction permet de sauvegarder le modèle à chaque fois que la losses de validation s'améliore (vérification à la fin de chaque epoch). Cette fonction permet de toujours conserver la meilleure version du modèle malgré le délai de fin prématurée que nous venons de voir.

cookedDishModel.py (l.194)

```
## We just save the best model, not the last one used
filepath = SAVE_MODEL_DIR + SAVE_MODEL_WEIGHT_NAME
model_checkpoint = ModelCheckpoint(filepath=filepath, monitor='
    val_loss', save_best_only=True, verbose=1, mode='min',
    save_weights
```

3.3.2 Le système de prédiction (demo.py)

Cette partie est beaucoup simple, dans un premier temps on va simplement recharger notre modèle à partir de deux fichiers de sauvegarde générés à la fin de l'apprentissage : les métadata de notre modèle contenues dans un fichier json et les weights du modèle contenus dans un fichier hdf5.

test.py (l.32)

```
json_file = open(SAVE_MODEL_DIR + SAVE_MODEL_JSON_NAME, 'r')
loaded_model_json = json_file.read()
json_file.close()

model = model_from_json(loaded_model_json)
model.load_weights(SAVE_MODEL_DIR + SAVE_MODEL_WEIGHT_NAME)
```

La démo proposée par ce script est automatisée : la seule chose à faire est de placer les images à tester dans le dossier défini par la constante PREDICT_DIR. Les prédictions sont ensuite modélisées pour indiquer la probabilité correspondant à la prédiction. Comme vous pouvez le voir, le modèle ne s'interesse pas vraiment à la classe "something else", il nous retournera toujours des statistiques pour notre classe principale. Si ces statistiques sont inférieures à 50% c'est que le modèle pense que la photo proposée appartient à l'autre classe.

test.py (l.194)

```
test_images =  [PREDICT_DIR+i for i in os.listdir(PREDICT_DIR)]
test, count = prep_data(test_images)
predictions = model.predict(test, verbose=0)

for i in range(0,count):
  print("\n" + "Image " + path_image[i] + ":")
  if predictions[i, 0] >= 0.5:
    print('I am {:.2%} sure this is a cooked dish'.format(predictions
        [i][0]))
```

```
9           else:
10            print('I am {:.2%} sure this is something else'.format(1-
                predictions[i][0]))
```

Chapitre 4

Choix du modèle, performances et analyse

4.1 Mise en garde

Attention, l'entrainement de ce modèle nécessite au minimum 6Go de mémoire vive disponible. L'entrainement du modèle a pris 40 minutes (dont 10 minutes de chargement d'image) avec deux NVDIA-970GTX. Exécuter ce modèle via le processeur prendrait environ 4 à 6 heures en CPU.

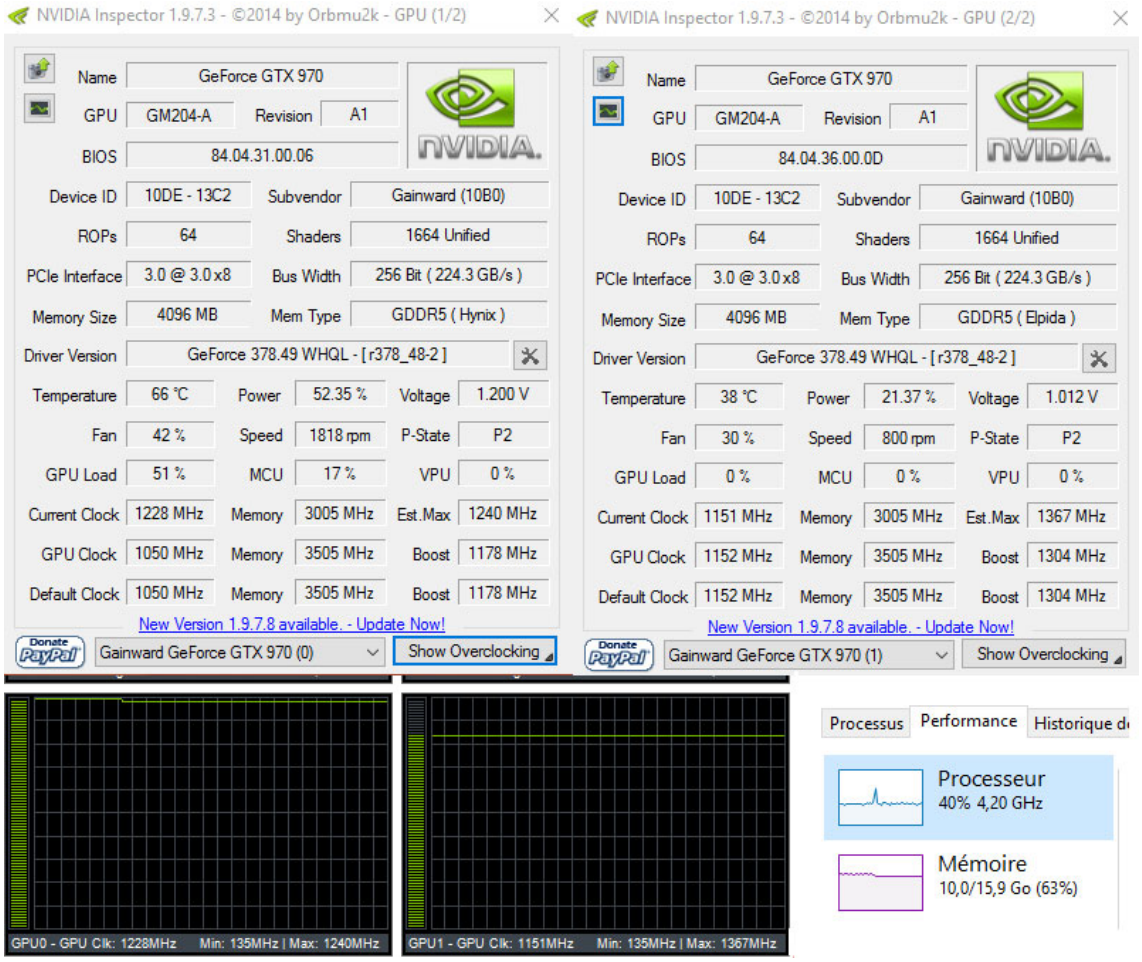

(a) Specs durant le training

4.2 Choix du modèle

Dans cette section je vais tâcher de montrer mon raisonnement pour mon choix final du modèle. J'ai sélectionné les quatre exemples qui ont fait avancer mon raisonnement mais sachez que j'ai généré environ 20 modèles différents pour trouver un modèle satisfaisant.

Mon choix c'est fait en trois étapes correspondant aux trois sous-sections ci-dessous : l'analyse de l'accuracy [1]/losses, l'analyse des courbes ROC et enfin l'analyse des prédictions de test.

Vous pouvez voir ci-dessous de quelle façon le modèle perçoit les deux classes :

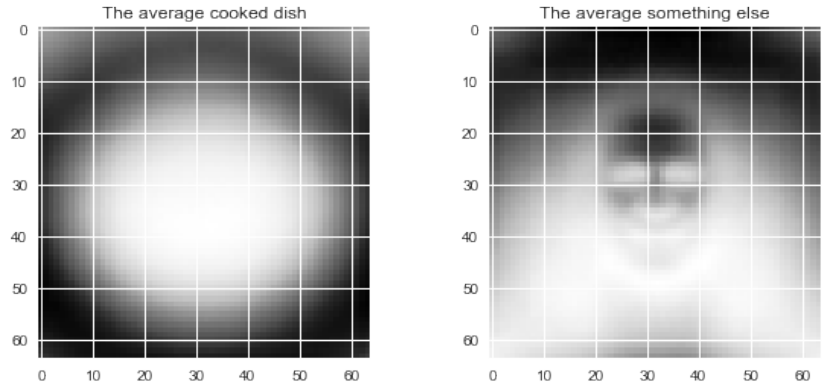

(a) Plat cuisiné moyen (b) Autre chose moyen

FIGURE 4.1 – Classe vue par le modèle

Enfin, pour s'y retrouver facilement, j'ai nommé chaque modèle de A à D de façon chronologique (le modèle A est le premier modèle que j'ai entrainé). Les différences entre ces modèles sont principalement des différences de taille de batch [2] et le pourcentage de données utilisées pour la validation :

— Modèle A : batch size = 16, validation = 35%
— Modèle B : batch size = 50, validation = 35%
— Modèle C : batch size = 50, validation = 45%
— Modèle D : batch size = 60, validation = 45%

4.2.1 Accuracy et Losses par epoch

Les premiers indicateurs auxquels je me suis intéressé pour le choix de mon modèle sont l'accuracy et la losses. Ils permettent de voir les performances du modèle, mais leur évolution par epoch est encore plus intéressante. C'est par le biais de cette évolution que l'on peut vérifier que le modèle n'entre pas dans un état d'overfitting [3] ou d'underfitting [4] (problème de généralisation du modèle).

1. accuracy : mesure à quelle fréquence le modèle choisit la bonne classe
2. Batch size : nombre de données propagées dans le réseau : permet de calculer le nombre d'itérations nécessaires par epoch.
3. Le modèle connait trop bien le jeu de donnée d'entrainement impactant son habilité à généraliser.
4. Le modèle n'arrive pas à généraliser (entrainement, validation et prédiction)

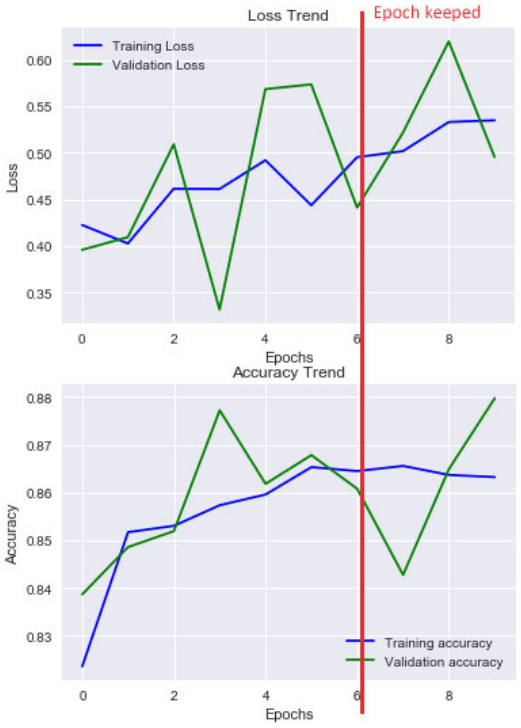

(a) Modèle A

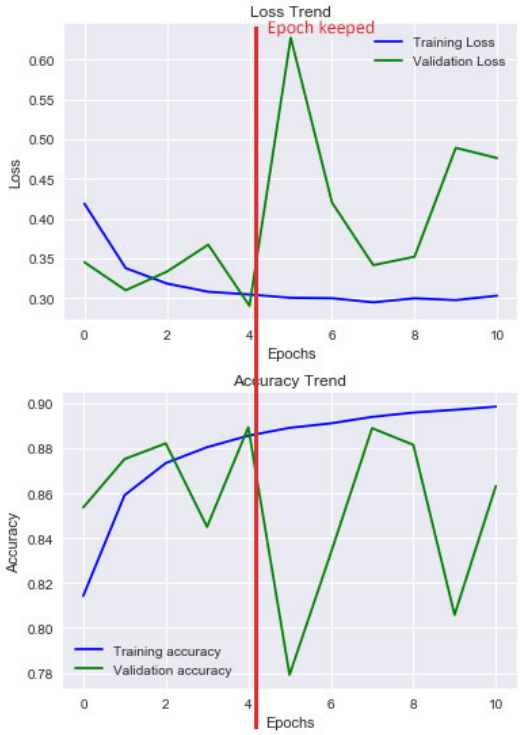

(b) Modèle B

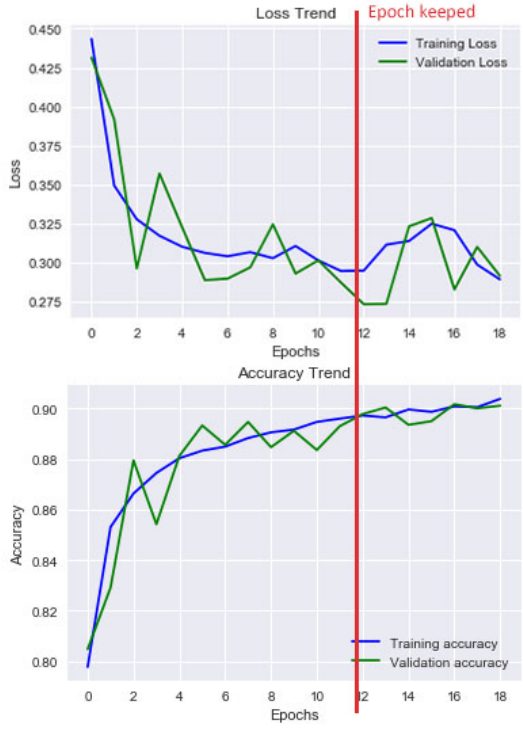

(c) Modèle C

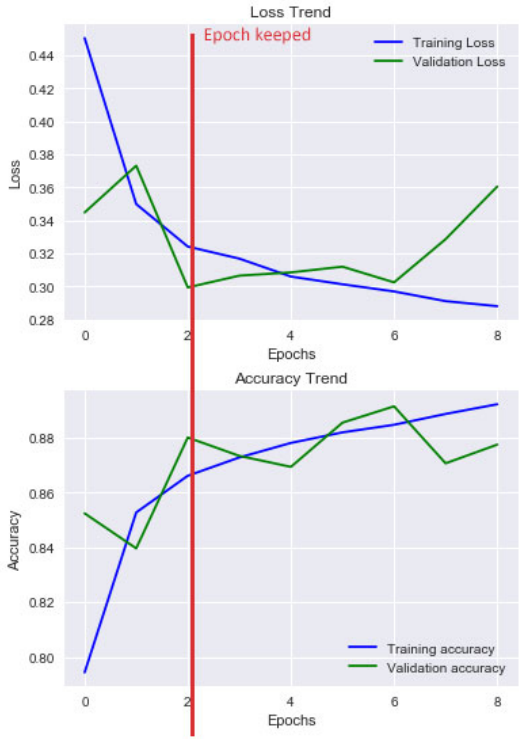

(d) Modèle D

FIGURE 4.2 – Accuracy and losses

Pour interpréter ces résultats (attention aux échelles, elles sont dynamiques en fonction des valeurs) je me suis basé sur ce modèle :

— Underfitting : Les erreurs de validation et d'apprentissage sont élevées (Losses élevé

et accuracy basse).
— Overfitting : Les erreurs de validation sont élevées alors que les erreurs d'apprentissage sont faibles.
— Bon ajustement : Les erreurs de validation sont faibles mais légèrement supérieures aux erreurs d'apprentissages
— Ajustement inconnu : Les erreurs de validation sont faibles mais les erreurs d'apprentissage sont "élevées".

Dans un premier temps, on remarque que les modèles A et B sont très instables : on constate des pics importants sur la validation. Cette dernière est globalement éloignée des valeurs de validation ce qui n'est pas une bonne chose (elle devrait être légèrement supérieure pour la losses et inférieure pour l'accuracy). Ces modèles oscillent selon les epochs entre overfitting et un ajustement inconnu.

Les deux autres modèles (C et D) ont des courbes beaucoup plus cohérentes (validation proche de l'apprentissage) et semblent donc plus pertinent. Le modèle C est conservé en epoch 12 alors que le modèle D a atteind ses meilleures performances dès l'epoch 2. Cette information couplée au fait que le modèle C n'a pas connu de cas flagrant d'overfitting (léger pic pendant l'epoch 2 mais la différence n'est que de 0.035 environ) semblerait donc être pour le moment le plus pertinent.

Notons que ces légers pics ne traduisent pas forcément de l'overfitting : le modèle utilisant une cross validation, il est tout à fait possible que les données de validation soient plus complexes à résoudre que les données d'apprentissage.

Quoi qu'il en soit, le modèle C et le modèle D rentre dans le cas "d'ajustement inconnu", il faudra donc analyser les courbes ROC et les prédictions de ces modèles afin de les départager et être sûr qu'ils sont efficaces.

4.2.2 Courbe ROC

La courbe ROC (Receiving Operating Characteristics) est une représentation graphique des performances d'un modèle. En ordonnée, on trouve la sensibilité (Le taux de vrai positif) et en abscisse, l'inverse de la spécificité (1- taux de faux positif). Comme le montre l'exemple d'interprétation suivant, plus la courbe se situe "haut" dans le graphique, plus le modèle est performant :

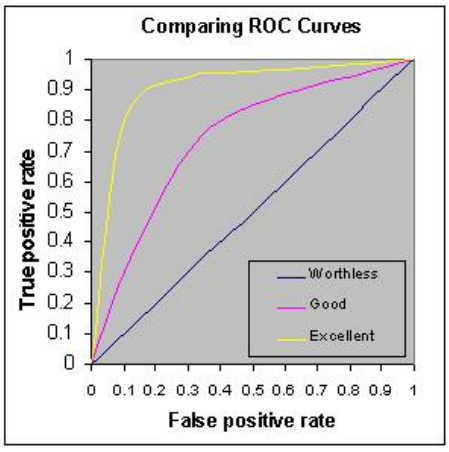

(a) Interprétation courbe ROC

Notons enfin que ces courbes correspondent aux taux d'erreurs de l'epoch retenus par le modèle.

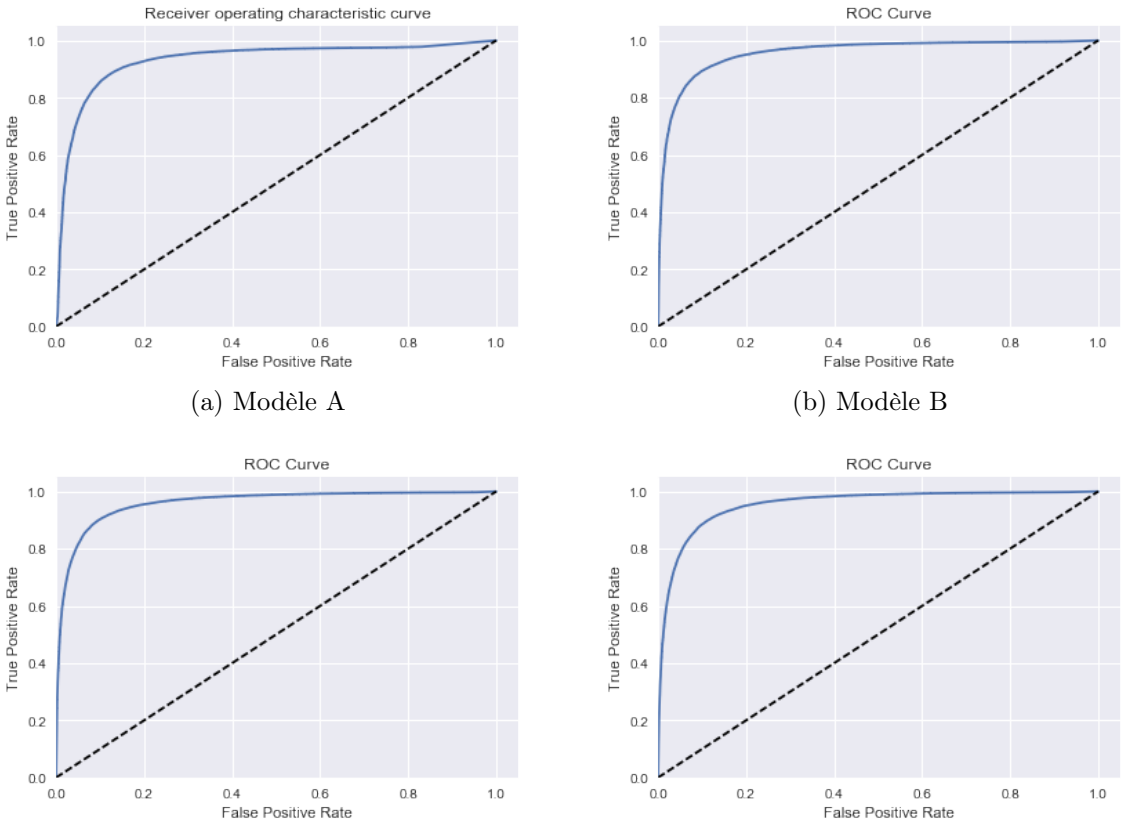

(a) Modèle A

(b) Modèle B

(c) Modèle C

(d) Modèle D

FIGURE 4.3 – Courbes ROC

Bien que les courbes des modèles A et B soient très légèrement moins bonnes, elles sont toutes excellentes. Cela ne veut bien entendu pas dire que notre modèle est parfait mais traduit une bonne performance de tous nos modèles.

Si un mauvais modèle (établissant de mauvaise prédiction) a malgré tout une courbe ROC excellente, cela signifi que le modèle (hardcode) est bon mais que le jeu de donnée d'une ou des deux classes n'est pas adapté.

Nous ne pouvons donc rien conclure de cette courbe ROC avant d'avoir analysé les performances de prédiction des modèles, si ce n'est que le "code" de notre modèle est bon.

4.2.3 Prédiction

Pour valider mon modèle à partir des prédictions (faites sur le modèle complètement entrainé), j'ai soigneusement choisi quatre images de plats et quatre images qui n'en sont pas.

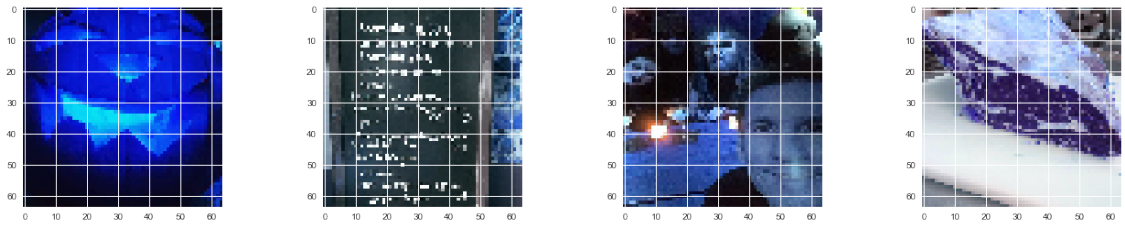

(a) Item 1 (b) Item 2 (c) Item 3 (d) Item 4

FIGURE 4.4 – Prédictions (classe autre chose)

Modèle	Item 1	Item 2	Item 3	Item 4
A	100%	98.39%	-67.06%	-69.09%
B	98.73%	100%	50.49%	-97.84%
C	99.92%	99.94%	-90.12%	68.02%
D	-81.84%	99.91%	-99.41%	-98.77%

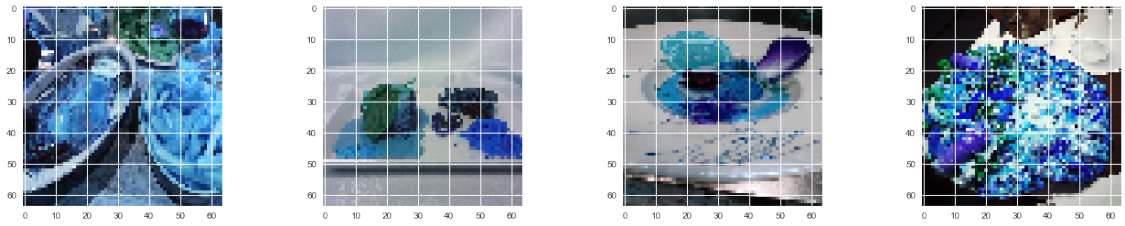

(a) Item 5 (b) Item 6 (c) Item 7 (d) Item 8

FIGURE 4.5 – Prédictions (classe plat cuisiné)

Modèle	Item 5	Item 6	Item 7	Item 8
A	89.80%	63.06%	99.59%	99.65%
B	89.69%	-58.22%	99.71%	97.32%
C	87.32%	57.96%	99.48%	96.58%
D	97.96%	92.77%	99.89%	99.69%

Il faut tout d'abord noter que les valeurs négatives correspondent à une erreur. Dans un premier temps, on peut exclure le modèle D : il est beaucoup trop confiant (rarement moins de 97% de certitude) et choisi presque toujours un plat.

Le modèle A, lui, échoue à la différenciation des deux "autres" les plus complexes ce qui le rend moins intéressant que les autres.

Enfin, le modèle B est le seul à différencier les visages de justesse mais il se trompe dans l'analyse du plat le plus complexe. Ainsi, le modèle C semble être le pertinent : il est d'ailleurs le seul modèle parmi tous mes essais (une vingtaine) à avoir choisi la bonne classe pour la pièce de viande brute. De plus, ses seuils de confiances affichés sont cohérents avec la difficulté de classification des images données.

Il faut bien garder à l'esprit que plusieurs de ces images ici sont difficiles. J'ai testé chaque modèle sur des photos plus classiques et le modèle B et C s'en sortent très bien (D est catastrophique : il indique quasiment toujours un plat).

4.2.4 Sélection du meilleur modèle

En mettant bout à bout chacune de ces trois analyses pour chacun des modèles, j'ai décidé de sélectionner le modèle C qui est toujours le plus pertinent à chaque étape. Le modèle B était également intéressant mais son instabilité (accuracy et losses) est préoccupante.

Je souhaite tout de même indiquer que je pense qu'un travail sur le jeu de données serait utile pour obtenir un modèle plus performant. La courbe ROC est une preuve de performance du modèle mais les prédictions indiquent que ce modèle pourrait encore être amélioré. Je n'ai malheureusement pas eu le temps de remanier ce dernier (les dataset sont gros et celà nécessite beaucoup d'analyse et de temps de calculs) mais je pense que le modèle C reste très satisfaisant.

Chapitre 5

Conclusion

5.1 Présentation des améliorations possibles

Faute de temps et du défi que représentais ce projet, je n'ai pas pu aller aussi loin que prévu. J'avais néanmoins effectué des recherches préliminaires sur plusieurs points que je souhaite exposer brièvement.

5.1.1 Implémentation dans un environnement tensorflow "less"

Actuellement le modèle est fonctionnel est peu établir des prédictions à la demande. Il n'est néanmoins pas exploitable à l'exterieur de son environnement complexe ce qui le relègue à l'état d'experimentation alors qu'il pourrait devenir un véritable outil.

Voici les différentes solutions pour utiliser ce modèle pré-entrainé à partir d'une autre application n'évoluant pas dans un environnement approprié :

- Keras-js : permet la création d'une application en VueJs pouvant charger le modèle directement dans le navigateur puis effectuer des prédictions à la demande.
- TensorFlow Serving : permets d'installer le réseau de neurones sur un serveur dans son environnement pour ensuite retourner des prédictions par le biais d'une API.
- TfDeploy : permet d'exporter un réseau de neurones pré-entrainé directement dans une application python par le biais de numpy.

5.1.2 Du modèle binaire vers un modèle multi-classe

Après une longue période de réflexion sur le sujet, je pense que transformer ce modèle binaire en modèle multi-classe n'est pas la solution pour labéliser chaque plat. En rajoutant des classes ont va également diminuer l'habilité de notre modèle à différencier un plat d'autre chose. Cela étant, au vu de notre problème de départ, je ne pense pas qu'il soit avisé de partir dans cette direction.

Cependant, je pense qu'il est également possible d'effectuer une labélisation sans déteriorer la qualité de la différenciation binaire : créer un second modèle. En effet, si le premier modèle binaire épure déjà les photos qui ne sont pas des plats, le second modèle pourra alors se focaliser sur la labélisation.

5.2 Problèmes rencontrés

Le premier problème majeur que j'ai rencontré est lié au fait que je me suis lancé dans ce projet avec absolument aucune connaissance en deep learning (ou même big data d'ailleurs) et réseaux de neurones automatisés. Ces lacunes ont entrainé des problèmatiques majeures quant à la compréhension du fonctionnement de cette technologie et du vocabulaire relatif à son utilisation. Il n'existe pas de "tutoriel du zero" dans le monde du deep learning et même les exemples les plus simples peuvent paraître totalement abstraits.

J'ai ensuite eu beaucoup de mal à installer l'environnement adéquate afin de pouvoir commencer à tester des modèles : j'ai mis trois jours à créer un environnement de travail fonctionnel. J'ai néanmoins fini par trouver une procédure plutôt simple et je suis désormais capable de réinstaller cet environnement sur windows et linux.

Enfin, le temps et la quantité de données à traiter a souvent été problématique : 10Go de data-set, 40 minutes par entrainement de modèle (sans compter les nombreux modèles qui ont buggé après 30mm de calculs durant la phase de développement).

5.3 Feedback

Quand j'ai choisi ce projet, je ne m'attendais absolument pas à développer un modèle de réseau de neurones. Ce projet tuteuré a été mon plus gros défi en matière de développement et j'ai plus d'une fois cru que je n'arriverais pas à le terminer dans les délais impartis étant donnée sa complexité (et mon manque d'expérience dans ce domaine).

Malgré tout, travailler sur ce projet a été un véritable plaisir, ainsi qu'une bonne opportunité de découvrir et d'apprivoiser la puissance du deep learning. Je pense sincèrement que ce n'est pas la dernière fois que je vais travailler sur un modèle de ce genre et je pense qu'ils vont devenir de plus en plus présents dans le monde du web.

5.4 Remerciements

Tout d'abord je tiens à sincèrement remercier François Rioult qui m'a encadré sur ce projet pour m'avoir conseillé et rassuré dans les moments de doutes.

Marc Houssaye pour m'avoir proposé ce sujet et ainsi donné, sans le savoir, l'opportunité de découvrir la puissance des systèmes de réseaux de neurones automatisés.

Frederic Jurie et Alexis Lechervy pour m'avoir indiqué des solutions/choix de départ, c'est grâce à leur expertise que j'ai pu démarrer ce projet.

Le Master DNR2i de l'Université de Caen Normandie pour m'avoir permis de suivre cette formation sans expérience de développement préliminaire.

5.5 Sources

Voici un extrait des sources principales qui m'ont permis de développer ce projet :

5.5.1 Littérature et documentation

- Machine Learning Attacks Against the Asirra CAPTCHA de Philippe Golle (Palo Alto Research Center).
- Very Deep Convolutional Networks for Large-Scale Image Recognition de Karen Simonyan et Andrew Zisserman
- Convolutional Neural Networks (CNNs / ConvNets) de la Stanford CS class
- Deep Learning and Neural Network Glossary de deeplearning4j
- RECIPE RECOGNITION WITH LARGE MULTIMODAL FOOD DATASET de Xin Wang, Devinder Kumar, Nicolas Thome, Matthieu Cord et Frédéric Precioso.
- Leveraging Context to Support Automated Food Recognition in Restaurants de Vinay Bettadapura, Edison Thomaz, Aman Parnami, Gregory D. Abowd et Irfan Essa
- Simultaneous Food Localization and Recognition de Marc Bolanos et Petia Radeva
- Wide-Slice Residual Networks for Food Recognition de Niki Martinel, Gian Luca Foresti et Christian Micheloni
- documentation Keras
- documentation Tensorflow
- documentation Kaggle

5.5.2 Data-set

- lfw face data-set
- Indoor Scene Recognition data-set
- EurasianCitiesBase data-set
- Visual Cognition Laboratory data-set
- KTH-ANIMALS data-set
- dogsVsCats data-set
- Caltech256 data-set
- voc2007 data-set
- mirflickr data-set
- ETHZ-Food-101 data-set